BarMatchIA

21.6.13 - Brief funcional: Predicción y recomendación

Insumo para diagrama UML - Capstone 2026-2

Objetivo

Permitir que el Administrador del Local consulte predicciones generadas por un modelo propio de BarMatchIA, entrenado y evaluado con datos controlados por el proyecto, y reciba recomendaciones asociadas que transformen dichas predicciones en información accionable para apoyar la toma de decisiones.

Participantes

- Administrador del Local.
- Aplicación web BarMatchIA.
- Servicio de Inferencia IA/ML controlado por BarMatchIA.
- Modelo predictivo entrenado y versionado.
- Componente BI / Analítica.
- Base de Datos / Persistencia.

Precondiciones

- El Administrador del Local se encuentra autenticado y autorizado para consultar información de su establecimiento.
- BarMatchIA dispone de datos históricos y operacionales suficientes para construir las variables requeridas por el problema predictivo implementado.
- Existe al menos un modelo predictivo propio previamente entrenado, evaluado, versionado e integrado a BarMatchIA.
- El modelo disponible corresponde a una versión considerada válida para generar inferencias dentro del contexto definido.
- El Servicio de Inferencia puede cargar o acceder al modelo vigente y procesar solicitudes provenientes de componentes autorizados de BarMatchIA.
- Los datos utilizados para entrenamiento e inferencia permanecen bajo control de BarMatchIA y no requieren enviarse a un proveedor externo de IA para obtener la predicción principal del MVP.
- La información utilizada respeta el alcance del establecimiento consultado y las reglas de acceso definidas.

Flujo principal

1. El Administrador del Local ingresa al módulo de predicciones y recomendaciones.
2. BarMatchIA solicita una predicción para el establecimiento y horizonte definido.
3. La aplicación o backend autorizado envía la solicitud al Servicio de Inferencia IA/ML controlado por BarMatchIA.

4. El Servicio de Inferencia obtiene las variables históricas y contextuales necesarias desde la capa analítica preparada por BI y, cuando corresponda, desde otras fuentes autorizadas de BarMatchIA; alternativamente puede recibir dichas variables ya preparadas según la arquitectura que posteriormente se defina.
5. El sistema valida que la información requerida se encuentre disponible y sea compatible con la versión del modelo vigente.
6. El Servicio de Inferencia carga o utiliza el modelo predictivo versionado correspondiente.
7. El modelo procesa las variables de entrada.
8. El Servicio de Inferencia genera una predicción asociada al problema de negocio implementado.
9. BarMatchIA conserva el contexto mínimo de la inferencia, incluyendo establecimiento, período u horizonte analizado, momento de generación y versión del modelo utilizada.
10. El resultado predictivo es devuelto a la aplicación.
11. BarMatchIA combina la predicción con información descriptiva de BI y reglas o contexto operacional relevante.
12. A partir de dicha información, BarMatchIA genera una o más recomendaciones comprensibles para el Administrador cuando exista fundamento suficiente.
13. Cada recomendación presenta al menos el contexto que la origina y una acción sugerida.
14. La aplicación muestra la predicción y las recomendaciones asociadas al Administrador del Local.
15. El Administrador analiza la información y decide si considera o no la recomendación dentro de su gestión.
16. BarMatchIA no ejecuta automáticamente cambios operacionales, configuraciones, cierres, reservas ni otras acciones como consecuencia directa de una recomendación.
17. Las predicciones y recomendaciones generadas quedan disponibles para seguimiento, evaluación y mejora posterior del componente inteligente cuando corresponda.

Principio central

La predicción principal del MVP será generada por un modelo entrenado, gestionado y desplegado bajo control de BarMatchIA; no dependerá del envío de datos operacionales a una API externa de inteligencia artificial para realizar la inferencia.

La predicción estima un comportamiento futuro y la recomendación propone una posible acción. Ninguna de las dos reemplaza la decisión del Administrador del Local.

BarMatchIA debe mantener una separación clara entre información descriptiva, resultado predictivo y recomendación, de manera que el Administrador pueda comprender por qué recibe una sugerencia y conserve siempre la decisión final.

Modelo propio y servicio de inferencia

El componente IA/ML se plantea como una capacidad propia del proyecto. El flujo conceptual considera entrenamiento, evaluación y versionado de un modelo, seguido de su publicación mediante una interfaz de servicio consumible por BarMatchIA.

La tecnología concreta de exposición del modelo se definirá posteriormente en arquitectura y stack. En esta etapa se establece únicamente que el modelo debe poder ser consultado como un servicio desacoplado del backend operacional y administrado dentro de una infraestructura controlada por BarMatchIA.

- El modelo puede ejecutarse localmente o desplegarse en infraestructura controlada por el proyecto, según los requisitos de capacidad y disponibilidad.
- El servicio debe recibir únicamente las variables necesarias para la inferencia.
- El acceso al servicio debe quedar restringido a componentes autorizados.
- La versión del modelo utilizada debe poder identificarse.

- El modelo y sus artefactos deben mantenerse bajo control del proyecto.

Propiedad, privacidad y control de los datos

El diseño del componente predictivo debe considerar desde su origen la propiedad y gobernanza de los datos utilizados para entrenamiento e inferencia.

- Los datos operacionales pertenecientes al ecosistema BarMatchIA no deben enviarse innecesariamente a terceros para realizar la inferencia principal.
- El entrenamiento debe utilizar únicamente datos autorizados y necesarios para el problema seleccionado.
- La inferencia debe aplicar minimización de datos, utilizando solo las variables requeridas por el modelo.
- Los accesos al servicio predictivo y a sus fuentes de datos deberán quedar protegidos por los mecanismos de seguridad definidos posteriormente.
- El almacenamiento, logs, versionado y trazabilidad del modelo deberán evitar exponer información que no sea necesaria para la operación o evaluación.

Estas definiciones se profundizarán posteriormente en arquitectura, seguridad y modelo de datos. Desde esta etapa se fija como principio que BarMatchIA mantiene control sobre el ciclo de vida del modelo, sus artefactos y los datos utilizados para entrenamiento e inferencia, evitando exponer información operacional a terceros cuando no exista una necesidad funcional justificada.

Problema predictivo del MVP

Release 1 debe integrar al menos un problema predictivo completamente implementado, evaluado y publicado para inferencia. La selección definitiva del problema se formalizará posteriormente en 21.8, evitando adelantar una decisión sin revisar objetivos, datos disponibles y viabilidad.

Entre los candidatos ya considerados se encuentran la estimación de demanda u ocupación futura y la predicción de no-show.

Enfoque de modelado

La elección entre modelos estadísticos, Machine Learning clásico y redes neuronales deberá basarse en resultados medibles y en la naturaleza del problema.

- Se debe establecer al menos un baseline o referencia simple.
- Se podrán evaluar uno o más modelos de Machine Learning.
- Una red neuronal o enfoque de Deep Learning se incorporará únicamente si los datos y resultados justifican su complejidad.
- No se considera obligatorio realizar fine-tuning ni utilizar Deep Learning para demostrar el componente inteligente.
- El modelo seleccionado debe ser defendible por desempeño, complejidad, interpretabilidad cuando corresponda y viabilidad de despliegue.

Estructura mínima de una predicción

- Problema o variable que se está estimando.
- Establecimiento al que corresponde.
- Período, fecha u horizonte de la estimación.
- Resultado generado por el modelo.

- Momento en que fue generada.
- Versión del modelo utilizada.
- Indicador de confiabilidad, probabilidad, rango u otra medida de incertidumbre cuando el tipo de modelo lo permita y resulte metodológicamente válido.

Estructura mínima de una recomendación

- Contexto o condición que activa la recomendación.
- Predicción o indicador relevante asociado.
- Acción sugerida al Administrador.
- Explicación breve que permita comprender la relación entre el contexto y la sugerencia.
- Carácter no obligatorio de la recomendación.

Flujo alternativo A - No existen datos suficientes para predecir

1. El Administrador solicita una predicción.
2. El Servicio de Inferencia revisa las variables disponibles o recibe una solicitud incompleta.
3. El sistema determina que no existe información suficiente o válida para utilizar el modelo de forma responsable.
4. La predicción no se genera.
5. BarMatchIA informa al Administrador que todavía no existen datos suficientes para ese análisis.
6. El módulo puede seguir mostrando información descriptiva disponible desde BI, diferenciándola claramente de una predicción.

Flujo alternativo B - Servicio o modelo no disponible

1. BarMatchIA solicita una predicción.
2. El Servicio de Inferencia detecta que el modelo requerido no se encuentra cargado, habilitado o en una condición válida para inferencia, o que el servicio no puede responder.
3. El sistema no genera un resultado sustituto ni consulta automáticamente una API externa para reemplazar la inferencia principal.
4. BarMatchIA informa temporalmente que la predicción no se encuentra disponible.
5. La operación normal de reservas y del establecimiento continúa funcionando de forma independiente.

Flujo alternativo C - La predicción posee alta incertidumbre

1. El modelo genera un resultado acompañado por una medida de incertidumbre o confianza aplicable.
2. BarMatchIA detecta que el resultado se encuentra bajo el criterio de confiabilidad definido para su interpretación.
3. La predicción puede mostrarse acompañada de una advertencia clara o limitar la generación de recomendaciones según las reglas que posteriormente se establezcan.
4. El Administrador puede consultar el contexto sin que BarMatchIA presente el resultado como una certeza.

La existencia y forma de esta medida dependerá del problema predictivo y del modelo finalmente seleccionado.

Flujo alternativo D - No existe una recomendación útil asociada

1. El Servicio de Inferencia genera una predicción válida.

2. BarMatchIA combina el resultado con BI y el contexto operacional.
3. El sistema determina que no existe una acción suficientemente justificada para recomendar.
4. La predicción se presenta al Administrador sin forzar una recomendación.
5. BarMatchIA evita generar sugerencias genéricas únicamente para completar la interfaz.

Flujo alternativo E - El Administrador no sigue la recomendación

1. BarMatchIA presenta una recomendación.
2. El Administrador evalúa la sugerencia.
3. Decide no aplicar la acción recomendada o adopta una decisión diferente.
4. BarMatchIA no modifica automáticamente la operación.
5. La decisión del Administrador no se interpreta por sí sola como un error del modelo.

Flujo alternativo F - La información de contexto cambia

1. Se genera una predicción o recomendación.
2. Posteriormente cambia información relevante del establecimiento o del período analizado.
3. BarMatchIA identifica que el contexto utilizado puede haber quedado desactualizado.
4. El sistema evita presentar una recomendación antigua como si necesariamente siguiera vigente.
5. Cuando corresponda, se solicita una nueva inferencia o se actualiza la información mostrada.

Relación con BI

BI proporciona información histórica, métricas y datos analíticos depurados que pueden utilizarse para construir datasets y variables de entrada del Servicio de Inferencia. El modelo predictivo no debe depender de consultar directamente registros transaccionales crudos cuando exista una fuente analítica preparada y trazable.

Ejemplo conceptual: BI puede mostrar que la ocupación de los viernes ha aumentado durante las últimas semanas; el modelo puede estimar la demanda del próximo viernes; la capa de recomendaciones puede sugerir revisar capacidad operacional o preparación del local si el resultado proyectado lo justifica.

Relación con la operación

El Servicio de Inferencia IA/ML no debe convertirse en una dependencia crítica para que el establecimiento pueda reservar, validar QR, registrar walk-ins, asignar mesas o mantener la ocupación.

Si la predicción no se encuentra disponible, BarMatchIA debe continuar operando mediante sus reglas funcionales y el Motor de Reservas y Disponibilidad.

La interfaz entre el backend operacional y el Servicio de Inferencia permitirá desacoplar el ciclo de vida del modelo respecto del resto de la aplicación. El protocolo, framework y forma de despliegue definitivos se decidirán posteriormente.

Evaluación y publicación del modelo

El modelo utilizado en Release 1 debe ser entrenado y evaluado con métricas apropiadas al problema seleccionado y comparado contra una referencia o baseline razonable. La elección del enfoque deberá justificarse por resultados, datos disponibles y complejidad.

Una vez seleccionado, el modelo deberá empaquetarse o persistirse como artefacto versionado y quedar disponible para el Servicio de Inferencia. La publicación del modelo forma parte del flujo de incorporación de IA al producto, aunque los mecanismos técnicos concretos se definirán posteriormente.

La definición formal del problema, variable objetivo, datasets, variables, preparación de datos, modelos candidatos, métricas y estrategia de evaluación se desarrollará en 21.8 y 21.9, aprovechando cuando corresponda las capas Raw, Stage y analítica definidas funcionalmente en 21.6.12.

Estado resultante

Datos controlados por BarMatchIA -> preparación y entrenamiento -> evaluación y selección del modelo -> artefacto versionado -> publicación en Servicio de Inferencia propio -> solicitud desde BarMatchIA -> predicción -> combinación con BI y contexto -> recomendación cuando existe fundamento -> Administrador decide -> operación permanece bajo control humano.

Reglas funcionales identificadas

- RF-175: Release 1 debe integrar al menos un problema predictivo implementado, evaluado y accesible desde BarMatchIA.
- RF-176: La predicción principal del MVP debe provenir de un modelo entrenado y gestionado bajo control de BarMatchIA.
- RF-177: El modelo seleccionado debe quedar disponible mediante un Servicio de Inferencia consumible por componentes autorizados de BarMatchIA.
- RF-178: Los datos requeridos para la inferencia principal no deben enviarse innecesariamente a proveedores externos de IA.
- RF-179: Toda predicción debe asociarse al establecimiento, horizonte o período y versión de modelo correspondiente.
- RF-180: BarMatchIA no debe generar una predicción cuando falten datos esenciales o las entradas no sean válidas para el modelo.
- RF-181: Si el Servicio de Inferencia o el modelo no se encuentran disponibles, la operación normal del establecimiento debe continuar funcionando.
- RF-182: La indisponibilidad del modelo no debe provocar automáticamente el uso de una API externa como mecanismo sustituto para la predicción principal.
- RF-183: BI e IA/ML deben mantener responsabilidades diferenciadas: BI describe información histórica e IA/ML estima comportamientos futuros.
- RF-184: Las recomendaciones deben derivarse de información contextual, descriptiva y/o predictiva identificable.
- RF-185: Una recomendación debe presentar al menos su contexto y la acción sugerida.
- RF-186: BarMatchIA no debe ejecutar automáticamente acciones operacionales como consecuencia directa de una recomendación.
- RF-187: El Administrador del Local conserva la decisión final sobre cualquier recomendación recibida.
- RF-188: Si no existe una recomendación suficientemente justificada, BarMatchIA puede presentar la predicción sin generar una sugerencia artificial.
- RF-189: Cuando el tipo de modelo permita una medida válida de incertidumbre o confianza, BarMatchIA podrá utilizarla para contextualizar el resultado.
- RF-190: Los resultados predictivos o recomendaciones cuyo contexto haya quedado desactualizado no deben presentarse como necesariamente vigentes.

- RF-191: El modelo implementado debe evaluarse mediante métricas adecuadas al problema y compararse contra una referencia razonable.
- RF-192: La complejidad del modelo debe justificarse por su desempeño y adecuación al problema, no por el uso obligatorio de Deep Learning.
- RF-193: El modelo seleccionado debe mantenerse como artefacto identificable y versionado antes de ser publicado para inferencia.
- RF-194: El Servicio de Inferencia debe utilizar únicamente las variables necesarias y respetar los controles de acceso que posteriormente se definan.

La nomenclatura RF se utiliza temporalmente como referencia de trabajo. Este flujo continúa la numeración cerrada en 21.6.12, por lo que sus reglas comprenden RF-175 a RF-194.

Decisiones pendientes para 21.8, 21.9, 21.13 y 21.14

- Problema predictivo definitivo de Release 1.
- Variable objetivo y horizonte temporal.
- Unidad de predicción: establecimiento, fecha, bloque horario, reserva u otra que se determine.
- Variables históricas y contextuales utilizadas como entrada.
- Datos reales, sintéticos o combinación utilizada durante experimentación y entrenamiento.
- Cantidad mínima de datos necesaria para habilitar una predicción.
- Baseline y modelos candidatos.
- Evaluación de alternativas de Machine Learning y, si corresponde, Deep Learning.
- Métricas de evaluación.
- Criterio para seleccionar y aprobar el modelo que será publicado.
- Formato de persistencia del artefacto entrenado.
- Mecanismo de versionado del modelo.
- Frecuencia o evento que gatillará nuevas inferencias.
- Forma definitiva de representar incertidumbre o confianza.
- Reglas exactas que transformarán predicciones e indicadores en recomendaciones.
- Conjunto inicial de recomendaciones incluidas en Release 1.
- Tecnología concreta del Servicio de Inferencia y contrato con el backend.
- Ubicación definitiva de despliegue: local, servidor controlado, nube u otra infraestructura.
- Autenticación, autorización, cifrado, logs y controles de acceso del servicio.
- Política de retención y minimización de datos utilizados en inferencia.
- Mecanismo futuro para evaluar utilidad de las recomendaciones.

Brief para diagrama UML

Tipo de diagrama sugerido: Diagrama de Secuencia UML.

Participantes mínimos

- Administrador del Local.
- Aplicación web BarMatchIA.
- Servicio de Inferencia IA/ML.
- Modelo predictivo versionado.
- Componente BI / Analítica.
- Base de Datos / Persistencia.

Flujo principal a representar

Administrador abre módulo IA -> Aplicación solicita predicción -> Servicio de Inferencia solicita o recibe variables históricas/contextuales -> BI/Persistencia entrega datos autorizados -> Servicio valida entradas -> utiliza modelo versionado -> Modelo genera predicción -> Servicio devuelve resultado + contexto de versión -> Aplicación obtiene información descriptiva de BI -> BarMatchIA genera recomendación cuando corresponde -> Aplicación muestra predicción + contexto + recomendación -> Administrador evalúa la sugerencia -> no existe ejecución automática sobre la operación.

Fragmentos alternativos mínimos

- No existen datos suficientes.
- Servicio o modelo no disponible.
- Predicción con incertidumbre elevada.
- Predicción válida sin recomendación útil.
- Administrador decide no seguir la recomendación.
- El contexto cambia y la predicción o recomendación deja de estar vigente.

Regla crítica

La inferencia principal de BarMatchIA debe provenir de un modelo propio publicado como servicio bajo control del proyecto. Los datos utilizados deben mantenerse dentro del perímetro definido por BarMatchIA y una recomendación solo debe generarse cuando exista fundamento suficiente, sin ejecutar acciones automáticamente.

No representar todavía

- Modelo definitivo.
- Framework de Machine Learning definitivo.
- FastAPI u otro framework concreto de exposición.
- Formato técnico definitivo del artefacto del modelo.
- Pipeline definitivo de features.
- Fine-tuning como requisito obligatorio.
- Deep Learning como requisito obligatorio.
- MLOps definitivo.
- Registro técnico definitivo de modelos.
- Tecnología de contenedores o infraestructura concreta.
- Endpoints y contratos definitivos.
- Protocolos.
- Microservicios definitivos.
- Decisiones arquitectónicas aún no definidas.